

Rerport Classificazione Binaria - presenza Acqua - EuroSAT100

EC (s337049)

1. Impostazione del problema

Il task è la distinzione acqua / non-acqua da immagini Sentinel-2, impostato come segmentazione semantica (maschera binaria per pixel) anziché come classificazione di scena: nell'applicazione di riferimento l'informazione utile è l'estensione del corpo idrico, non la presenza di acqua nell'immagine.

Il punto di partenza è il tutorial TorchGeo su *Earth Surface Water* (`cordmaur/earth_surface_water`), esteso in tre direzioni: analisi preliminare dei dati, confronto tra due configurazioni di input sulla stessa architettura, valutazione a due livelli con analisi degli errori. L'obiettivo non era ottimizzare la metrica.

2. Dati e verifiche preliminari

Il dataset comprende 64 scene di training e 31 di validation, sei bande (B02, B03, B04, B08, B11, B12) a 10 m di risoluzione, con maschera binaria di verità. La valutazione finale copre circa 64 milioni di pixel.

Tre controlli precedenti al training, tutti con ricaduta pratica:

Sistemi di riferimento. Le 64 scene di training ricadono in **sedici CRS UTM distinti** (da EPSG:32612 a EPSG:32754). Campionare patch da proiezioni diverse senza riportarle a un riferimento comune produce patch di estensione fisica incoerente a parità di dimensione in pixel. È stato quindi imposto un CRS unico (EPSG:3395) con risoluzione fissa a 10 m, così che una patch 512×512 corrisponda sempre a circa 5,1 km di lato.

Distribuzione geografica. I centroidi delle scene, proiettati su mappa mondiale, mostrano un dataset globale ed eterogeneo (in un singolo batch da quattro patch: Sahel, Islanda, Borneo, Carelia). La variabilità di performance tra scene osservata più avanti non è quindi rumore, ma eterogeneità reale di bioma, illuminazione e tipologia di corpo idrico.

Validazione dei *bounds*. I *bounds* di ciascuna patch sono stati convertiti in coordinate WGS84 (quattro angoli e centro) e verificati a campione su base cartografica, sia per validare la catena di riproiezione, sia per constatare che in diversi siti la situazione attuale differisce visibilmente da quella del dataset, che è del 2019.

3. Esperimenti

Architettura identica nei due casi: DeepLabV3 con backbone ResNet50, due classi in uscita, Adam con learning rate 10^{-4} e weight decay 0,01, otto epoche, batch da quattro patch 512×512 , 130 patch campionate per epoca, riflettanze scalate per 10.000.

Indici spettrali calcolati con `torchgeo.transforms.indices`: NDWI (green-NIR) e MNDWI (green-SWIR2) per l'acqua, il secondo più robusto su suolo nudo e superfici costruite; NDVI come discriminante negativo sulla vegetazione.

Configurazione A — nove canali. Sei bande grezze più i tre indici. Richiede la sostituzione del primo layer convolutivo del backbone, nativamente a tre canali.

Configurazione B — tre canali di soli indici. Bande grezze scartate, rete lasciata nella struttura originale a tre canali.

L'ipotesi alla base di B: se l'acqua è identificabile da un rapporto tra bande, fornire direttamente quel rapporto può risultare più efficace che fornire tutte le bande e demandare alla rete la ricostruzione della relazione, disponendo di 130 patch per epoca.

4. Risultati

Valutazione per pixel	A — nove canali	B — tre indici
Accuracy	0,9678	0,9678
Precision	0,8860	0,9678
Recall	0,9204	0,9678
F1	0,9029	0,9678
IoU acqua	0,8230	0,9678
Falsi positivi su pixel non-acqua	2,30 %	0,9678

L'accuracy per pixel è fuorviante in presenza di forte sbilanciamento: in metà delle scene l'acqua sta sotto il 15% dei pixel, quindi una predizione costante otterrebbe già valori elevati. Le metriche sono state perciò calcolate anche per singola scena, definendo accettabile una scena con precision $\geq 90\%$ e recall $> 90\%$.

Valutazione per scena	A — nove canali	B — tre indici
Scene accettabili	12 / 31	14 / 31
Scene con precision $\geq 90\%$	17	22
Scene con recall $> 90\%$	14	14

La configurazione a soli indici risulta superiore su quasi tutti gli indicatori. Il guadagno più netto riguarda i falsi positivi, ridotti di circa un terzo. Il costo è un recall leggermente inferiore, cioè qualche corpo idrico mancato in più: per un uso di mappatura il trade-off appare favorevole, ma dipende dal costo relativo dei due errori nell'applicazione.

5. Analisi errori

Il confronto visivo tra scene migliori e peggiori (RGB, NIR, SWIR, maschera predetta, maschera reale e mappa TP/FN/FP) evidenzia un pattern ricorrente in entrambe le configurazioni: le prestazioni sono elevate sui corpi idrici estesi e compatti — laghi, bacini, coste — e degradano sui corsi d'acqua stretti e sulle scene in cui l'acqua è frammentata o marginale.

La verifica quantitativa su tutte le 31 scene, correlando la frazione di pixel realmente d'acqua con l'F1 ottenuto, conferma l'osservazione:

6. Limiti

Il confronto A/B non è pienamente controllato. In torchvision, l'invocazione di `deeplabv3_resnet50` con `weights=None` mantiene comunque il backbone ResNet50 pre-addestrato su ImageNet; la sostituzione del primo layer convolutivo in A ne azzerà i pesi pre-addestrati, mentre in B il layer resta intatto. Parte del vantaggio di B potrebbe quindi derivare dal pre-training anziché dagli indici: per isolare l'effetto occorrerebbe reinizializzare i nove canali replicando i pesi originali sui canali aggiuntivi.

Manca inoltre una baseline non addestrata — una soglia su NDWI o MNDWI, anche con Otsu — necessaria per stabilire quanto la rete aggiunga rispetto a un criterio puramente spettrale.

Sul piano metodologico: non è presente un ciclo di validazione durante il training (viene monitorata la sola train loss, peraltro oscillante), quindi non vi è early stopping né selezione del checkpoint migliore; il validation set funge anche da test set, in assenza di uno split a tre; il pre-processing è asimmetrico, con normalizzazione applicata solo in A. Infine, con campionamento casuale delle patch il termine “epoca” non ha il significato consueto.

7. Conclusioni

Due indicazioni principali. La prima è che la scelta delle feature in input pesa più della quantità di dati forniti: tre canali costruiti su base fisica superano nove canali comprensivi delle bande grezze, con un terzo dei falsi positivi. Con dataset ridotti e poche epoche, incorporare conoscenza di dominio nell'input risulta più efficiente che demandarne la scoperta al modello — con la riserva sul pre-training sopra indicata.

La seconda è che l'errore non è distribuito casualmente ma concentrato sulla geometria sottile, e il fattore limitante sembra essere la risoluzione a 10 m rispetto alla larghezza tipica dei corsi d'acqua. La distinzione è operativamente rilevante: un modello più capace non risolverebbe il problema, mentre lo farebbero un dato a risoluzione più fine o una loss che pesi esplicitamente i pixel di bordo. In prospettiva di analisi temporale di un corpo idrico, sapere dove il modello è affidabile ha valore almeno pari alla metrica aggregata.

	A — nove canali	B — tre indici
Correlazione di Spearman	0,72	0,57
F1 medio, scene sotto il 10% di acqua ($n = 12$)	0,70	0,73
F1 medio, scene sopra il 25% di acqua ($n = 10$)	0,95	0,92

Nella configurazione B, la scena migliore (29% di acqua) raggiunge $F1 = 0,988$ e una scena al 77% arriva a 0,984; all'estremo opposto, una scena al 7,0% si ferma a 0,337 con recall 0,21, e una al 7,2% ha precision 0,93 ma recall 0,45.

La spiegazione più plausibile è geometrica prima che spettrale. Un fiume largo 30–50 m occupa tre-cinque pixel a 10 m di risoluzione, e gran parte di essi è *mista*: la firma spettrale media acqua e riva, l'NDWI scivola verso la

soglia e l'ambiguità viene risolta verso la classe maggioritaria, cioè non-acqua. Sui laghi il fenomeno è marginale, perché i pixel misti sono confinati al perimetro. Ciò spiega anche la maggiore severità del pattern nella configurazione a nove canali, dove la banda grezza è su pixel misto ancora più ambigua del rapporto tra bande.