

Segmentazione per classificazione binaria acqua/non-acqua da immagini Sentinel-2 con TorchGeo

EC (s337049)

1. Obiettivo e riferimento

L'obiettivo è la distinzione acqua / non-acqua in immagini Sentinel-2, sul dataset *Earth Surface Water*. Il problema è impostato come segmentazione: la classificazione a livello di immagine viene poi ricavata aggregando le predizioni per pixel. Il punto di partenza è il tutorial TorchGeo (https://docs.torchgeo.org/en/stable/tutorials/earth_surface_water.html), da cui derivano lo scaling delle riflettanze, le statistiche per banda, gli indici spettrali e la prima configurazione di rete. Le estensioni riguardano le verifiche preliminari sui dati, la valutazione su immagini intere e il confronto tra due configurazioni di input.

2. Flusso di lavoro

Caricamento. Il dataset (64 immagini di training, 31 di validation, sei bande a 10 m con mask binaria) è caricato in due *RasterDataset* separati per immagini e mask, uniti poi con *IntersectionDataset*.

Sistemi di riferimento. L'ispezione dei CRS nativi mostra che le immagini di training ricadono in zone UTM diverse. Quindi vengono riproiettate su EPSG:3395 a risoluzione fissa di 10m: senza un riferimento comune, patch di pari dimensione in pixel coprirebbero estensioni diverse a seconda della scena, mentre così una patch 512×512 corrisponde sempre a circa 5,1 km di lato.

Collocazione geografica. Le posizioni delle immagini, riproiettate in EPSG:4326 e visualizzate su mappa mondiale, evidenziano un dataset globale ed eterogeneo: un elemento utile in seguito per interpretare la variabilità dei risultati tra immagini. Le coordinate WGS84 dei bordi e dei singoli pixel sono state ricostruite tramite la matrice affine e verificate su base cartografica, sia per validare la catena di riproiezione sia, come effetto collaterale, per constatare che in diversi punti la situazione odierna differisce da quella del dataset, che è del 2019.

Preprocessing e modello. Alle sei bande sono concatenati tre indici: NDWI e MNDWI per l'acqua, NDVI per la vegetazione, quest'ultimo come discriminante negativo. Il primo convolution layer del backbone di ResNet50 è sostituito per accettare nove canali: è la configurazione A, nella B invece verrà lasciato a 3 canali.

Valutazione su immagini intere. L'inferenza è eseguita sull'immagine completa, a tasselli con padding, anziché su patch campionate, in modo da ottenere una maschera confrontabile con la ground truth a piena estensione. Oltre all'aggregato per pixel si ricava così una confusion matrix per singola immagine. I due livelli rispondono a esigenze diverse: con l'acqua come classe minoritaria, la sola accuratezza per pixel sarebbe poco informativa.

Modifica sull'input della rete (configurazione B). La configurazione B impiega tre soli canali, gli indici calcolati, in luogo dei nove. Anche in B il primo convolution layer viene reinizializzato: diversamente, B partirebbe con un primo layer pre-addestrato che in A risulta invece azzerato, e la differenza non sarebbe attribuibile all'input. L'ipotesi verificata in parte è che, se l'acqua è riconoscibile da un rapporto tra bande, fornirlo direttamente alla rete valga

più che lasciarne a essa la ricostruzione, considerando poi che il training time rimane sostanzialmente invariato tra le due configurazioni (c.a. 7 minuti i copilazione da tempo esecuzione cella)

Confronto qualitativo. Per le due immagini migliori e le due peggiori per F1 sono affiancati su otto pannelli bande e colori (RGB, NIR, SWIR1, SWIR2), mask predetta e reale, overlay e mappa TP/FN/FP.

3. Risultati

Sull'aggregato per pixel (Tabella 1) la configurazione B resta superiore: F1 0,8768 contro 0,8444 e falsi positivi più che dimezzati, dall'1,06 % allo 0,45 % dei pixel senza acqua. A livello di immagine il risultato cambia: la configurazione A soddisfa entrambi i criteri in 11 casi contro gli 8 di B. La tabella per immagine ne indica la causa: in tre immagini B non predice acqua in alcun punto, con recall nullo e precision non definita, mentre A non azzerava mai. Il guadagno di B è quindi concentrato sulla precision, che sale a 0,9720, mentre il recall resta il punto debole di entrambe le configurazioni (0,7705 per A, 0,7986 per B).

La dispersione tra immagini è ampia in entrambi i casi: gli F1 vanno da 0,9879 a 0,3311 in A e da 0,9803 a 0,2038 in B. Il confronto visivo finale evidenzia una tendenza ricorrente in entrambe le configurazioni: le prestazioni calano sulle immagini in cui l'acqua è poco estesa e frammentata, tipicamente corsi d'acqua stretti, mentre restano elevate dove il corpo idrico è compatto e occupa una porzione rilevante della scena, come nei bacini lacustri. La relazione non è però sistematica: tra i casi peggiori compaiono anche immagini con frazione d'acqua elevata, segno che l'estensione del corpo idrico non è l'unico fattore in gioco.

4. Osservazioni

Il training è stato eseguito senza hyperparameter tuning, con un numero fisso di epochs e senza un test set separato dal validation. Le risorse a disposizione hanno orientato le scelte verso un impianto semplice, quindi i valori riportati vanno letti come indicativi.

Il comportamento più evidente è che in tre immagini la configurazione B non predice acqua in alcun punto. Trattandosi di immagini in cui l'acqua occupa una porzione ridotta della scena, il modello sembra convergere verso la classe maggioritaria. Un possibile intervento sarebbe introdurre un peso nella funzione di loss, in modo che sbagliare su un pixel d'acqua costi più che sbagliare su un pixel senza acqua

Tabella 1: Confronto tra le due configurazioni di input. Accettabile: precision $\geq 90\%$ e recall $> 90\%$.

	A (9 CH)	B (3 CH come indici)
<i>Per pixel</i>		
Precision	0,9339	0,9720
Recall	0,7705	0,7986
F1	0,8444	0,8768
FP su non-acqua	1,06 %	0,45 %
<i>Per immagine (su 31)</i>		
Accettabili	11	8
Precision $\geq 90\%$	23	24
Recall $> 90\%$	11	9
Nessun pixel predetto	0	3